Cómo mejorar la calidad de las respuestas de un LLM

De la variabilidad al output estructurado y al RAG

AUTOR/A
Sebastián Egaña Santibáñez

FECHA DE PUBLICACIÓN
21 de octubre de 2026

1 El problema que vimos en clase

Hicimos la misma consulta **100 veces** a un modelo de lenguaje, con los casos A, B y C de la práctica de diagnóstico. Resultado:

- **Caso B** (saturación 86%): 98 de 100 dijeron neumonía, pero con redacción distinta (“Neumonía”, “Neumonía severa”, “Neumonía grave”).
- **Caso A** (tos seca, fiebre): 70 dijeron “infección viral respiratoria” y el resto, variantes de gripe.
- **Caso C** (sin síntomas): “salud óptima”, “salud general”, “paciente sano”… significan lo mismo, pero con palabras distintas.

Hay **dos problemas distintos** mezclados:

Problema	Ejemplo	Qué lo arregla
Variabilidad de forma: el sentido es el mismo, pero las palabras cambian	Caso C: tres frases para decir “sano”	Estructurar el output
Falta de conocimiento o de fundamento: el modelo inventa o responde con datos desactualizados	Una política interna que el modelo nunca vio	RAG (darle la información)

Y una regla de fondo: **un LLM predice la palabra más probable, no consulta hechos**. Todas las técnicas de esta guía son formas de acotar esa libertad.

2 Nivel 1: pedir mejor (prompting)

Es lo más barato y suele dar la mayor mejora inicial.

Técnica	Qué es	Ejemplo
Dar rol y contexto	Decir quién es y para qué se usa la respuesta	“Eres un analista de riesgo. La respuesta la leerá un gerente.”
Instrucciones precisas	Reemplazar lo vago por lo verificable	En vez de “resume”, “resume en 3 viñetas de máximo 15 palabras”

Técnica	Qué es	Ejemplo
Ejemplos en el prompt (*few-shot*)	Mostrar 2 o 3 casos resueltos como modelo	"Entrada: … → Salida: …"
Permitir "no sé"	Dar una salida legítima para cuando falta información	"Si el dato no está, responde `no_disponible`."
Bajar la temperatura	Parámetro que controla cuánto "arriesga" el modelo al elegir palabras	Temperatura 0 a 0,2 para tareas de clasificación

> **Ojo con la temperatura:** bajarla reduce la variabilidad, pero **no la elimina** ni hace que el modelo acierte más. Solo lo vuelve más consistente, incluso en sus errores.

3 Nivel 2: estructurar el output

3.1 La idea

En vez de aceptar texto libre, **le pedimos al modelo que responda con un formato fijo**, normalmente JSON, con campos y valores permitidos. Así la respuesta se puede contar, filtrar y validar con un programa.

3.2 Aplicado al caso C

Texto libre (lo que vimos en clase):

```
"El paciente presenta un estado de salud óptimo."
"Paciente sano, sin hallazgos relevantes."
"Salud general conservada."
```

Con output estructurado, el prompt dice:

```
Responde solo con un JSON con esta forma:
{
  "diagnostico": "sano" | "infeccion_viral" | "neumonia" | "otro",
  "confianza": "alta" | "media" | "baja",
  "justificacion": "máximo 20 palabras"
}
```

Y las respuestas pasan a verse así:

```
{"diagnostico": "sano", "confianza": "alta", "justificacion": "Sin síntomas ni signos vitales alte
```

Ahora las **100 consultas caen en 4 categorías cerradas**, y la barra de "otras variantes" desaparece: se puede **medir** cuántas veces el modelo dice cada cosa.

3.3 Qué ganamos y qué no

Lo que mejora	Lo que NO mejora
Consistencia de **forma**: mismas categorías, mismo formato	Que la categoría elegida sea **correcta**
Se puede **validar** automáticamente (¿vino un valor permitido?)	Que el modelo no se invente un dato dentro del formato
Se puede **integrar** con otros sistemas (planillas, bases, flujos)	El sesgo ni la falta de conocimiento
Se puede **medir** la variabilidad real	

> **Estructurar es ordenar la respuesta, no garantizar que sea verdadera.** Un JSON perfectamente válido puede contener un diagnóstico equivocado.

3.4 Cómo hacerlo en la práctica

1. **Con el prompt:** describir el formato y los valores permitidos (lo más simple, sirve en cualquier chat).
2. **Con la herramienta:** muchas APIs ofrecen "modo JSON" o "salida estructurada" con un esquema, que obliga al modelo a respetarlo.
3. **Con una validación posterior:** el programa revisa el JSON; si no cumple, reintenta o lo marca para revisión humana.

4 Nivel 3: medir la variabilidad, no adivinarla

Ya sabemos que una sola respuesta no basta. Con salida estructurada podemos:

- **Repetir la consulta varias veces** (por ejemplo, 5) y quedarnos con la respuesta más frecuente (*votación*).
- **Usar el acuerdo como señal:** si 5 de 5 dicen "neumonía", hay más confianza; si se reparten 2-2-1, **se deriva a una persona**.
- **Armar un set de prueba**: 30 a 50 casos con la respuesta esperada, definida por expertos. Cada vez que se cambia el prompt o el modelo, se vuelve a correr y se mide el porcentaje de acierto.

Es la misma lógica del **test de humo** de la sesión, pero repetible y con números.

5 Nivel 4: RAG, darle al modelo la información

5.1 El problema que resuelve

El modelo solo sabe lo que vio al entrenarse. No conoce los **documentos de tu empresa**, tus políticas ni lo ocurrido después de su fecha de corte. Cuando no sabe, **igual responde** con seguridad: esa es la causa de las "alucinaciones".

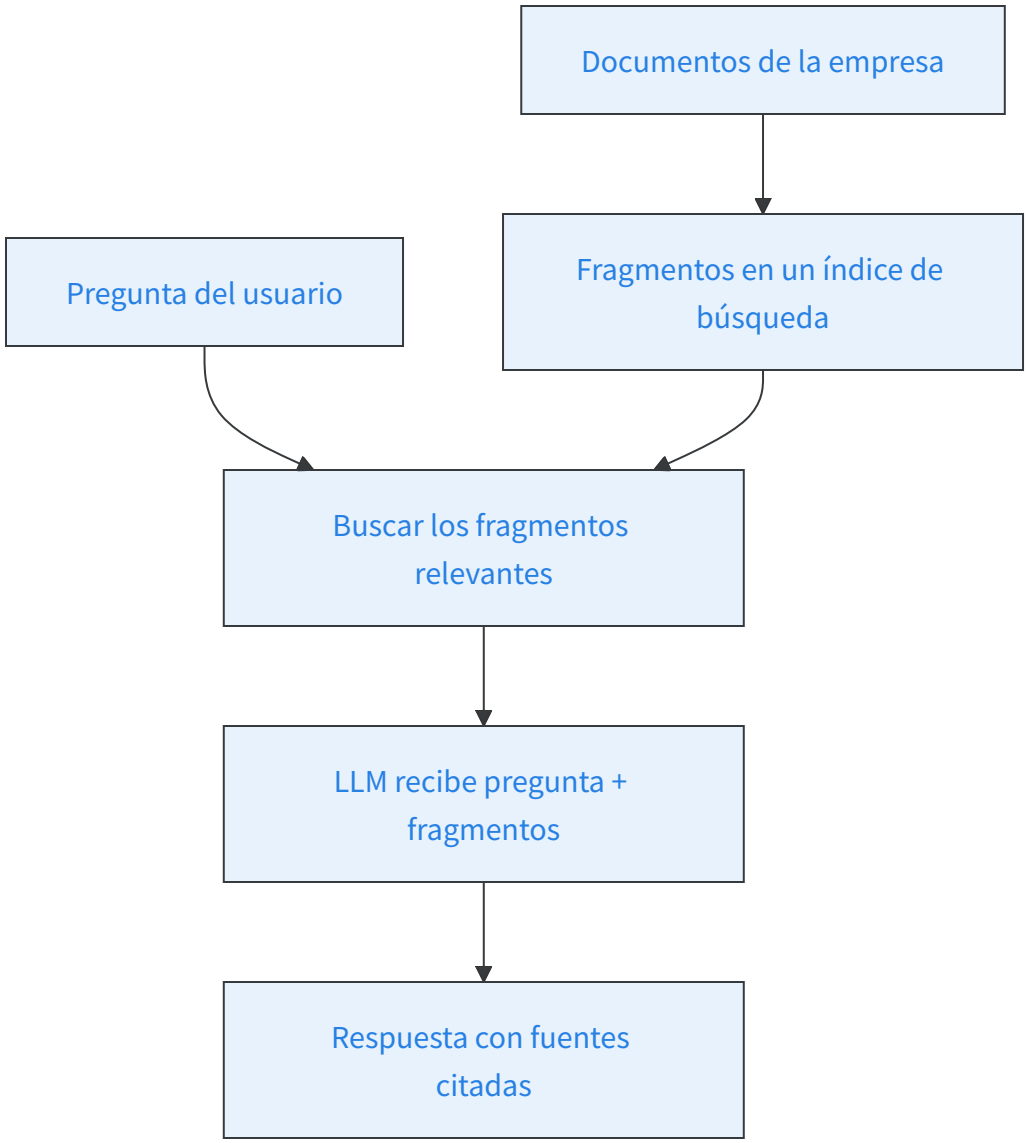
5.2 La idea, con una analogía

Es la diferencia entre un **examen de memoria** y un **examen con libro abierto**:

- **Sin RAG:** el modelo responde de memoria.
- **Con RAG:** antes de responder, el sistema **busca en tus documentos** los párrafos relevantes y se los entrega junto con la pregunta, con la instrucción de responder **solo** con esa información.

RAG significa *Retrieval-Augmented Generation*: generación aumentada por recuperación.

5.3 Cómo funciona



1. **Preparación (una vez):** los documentos se dividen en fragmentos y se indexan, de modo que se puedan buscar **por significado**, no solo por palabra exacta.
2. **Recuperación (en cada pregunta):** el sistema encuentra los 3 a 5 fragmentos más relacionados con la pregunta.
3. **Generación:** el modelo recibe la pregunta y esos fragmentos, y responde apoyándose en ellos.
4. **Citas:** la respuesta indica de qué documento y sección salió, para poder verificarla.

5.4 Ejemplo

Pregunta de un ejecutivo: *"¿Cuántos días de plazo tiene un cliente para pedir un reembolso?"*

Ejemplo ilustrativo con una política ficticia.

	Sin RAG	Con RAG
Respuesta	"Normalmente 30 días." (genérica, probablemente inventada)	"10 días hábiles desde la compra (Política de Reembolsos v3, sección 2.1)."
Verificable	No	Sí: se abre el documento citado

5.5 Qué ganamos y qué no

Lo que mejora	Lo que sigue siendo riesgo
Respuestas basadas en **tus datos**	Si el documento está **desactualizado o es incorrecto**, la respuesta también
Menos invención, y con **fuentes**	Si la búsqueda trae el fragmento equivocado, el modelo responde bien… sobre el texto equivocado
Se actualiza **cambiando documentos**, sin reentrenar el modelo	Los documentos pueden contener **datos sensibles**: hay que definir quién ve qué
	El modelo aún puede interpretar mal lo que lee

> **RAG traslada el problema de calidad desde el modelo hacia los documentos.** Los 4 Enemigos Silenciosos siguen aplicando: calidad de datos, histórico, representación.

5.6 Cuándo conviene RAG

- Hay conocimiento **propio y cambiante** (políticas, contratos, manuales, normativa).
- Se necesita **trazabilidad**: saber de dónde salió cada respuesta.
- Los documentos están **ordenados y vigentes**. Si no lo están, ese es el primer proyecto.

6 Resumen: ¿qué técnica usar?

Si el problema es…	Técnica	Esfuerzo
Respuestas vagas o mal enfocadas	Mejor prompt: rol, ejemplos, “no sé”	Bajo
Las mismas ideas con distintas palabras, difícil de contar o integrar	**Output estructurado** (JSON con valores cerrados)	Bajo a medio
No sé si puedo confiar en una respuesta	**Repetir y medir** el acuerdo, más un set de prueba	Medio
El modelo no conoce mis datos o inventa	**RAG** con documentos vigentes y citas	Medio a alto
Decisión de alto impacto	**Revisión humana** de los casos dudosos	Depende del volumen

Las técnicas **se combinan**: un buen sistema suele pedir un JSON, apoyarse en RAG para el contenido, repetir cuando hay dudas y derivar a una persona cuando no hay acuerdo.

7 Preguntas del líder antes de aprobar un proyecto con LLM

1. ¿Qué formato tiene la salida y quién la valida?
2. ¿Probaron la **misma consulta varias veces**? ¿Qué porcentaje de acuerdo hubo?
3. ¿Con qué **casos de prueba** miden la calidad, y quién definió la respuesta correcta?
4. ¿De qué **documentos** sale la información y quién los mantiene actualizados?
5. ¿Qué pasa cuando el modelo **no está seguro**? ¿Hay revisión humana?