

Skill de Auditoría con los 4 Enemigos Silenciosos

Actividad 02 — Fundamentos de Datos para la Toma de Decisiones Estratégicas con IA

Sebastián Egaña Santibáñez

2026-07-06

Actividad en dos partes: primero evalúas el caso con tu propio criterio, luego lo auditas con un LLM usando un prompt estructurado. Al final comparamos ambos resultados. **Tiempo total:** ~15 minutos.

Cada grupo elige **uno** de los dos casos (o el facilitador los asigna).

Caso A: Fintech — Créditos Automáticos

Proyecto: Créditos Automáticos por Historial

Institución: Banco de consumo, ~800.000 clientes activos

Área responsable: Gerencia de Riesgo, con apoyo del equipo de Datos

Objetivo declarado: otorgar o rechazar créditos de forma automática, sin intervención humana, para reducir el tiempo de aprobación de días a segundos.

Datos utilizados:

- Fuente: 10 años de historial interno de otorgamientos y morosidad (2015-2025)
- Solo se incluyeron solicitudes que fueron aprobadas en ese período
- Variables: monto solicitado, ingreso declarado, comuna, edad, historial de pago, ¿fue castigado contablemente?
- Muestra de entrenamiento: 250.000 operaciones

Modelo: Gradient Boosting. Métrica en pruebas: 97% de precisión.

Validación: split 80/20 aleatorio sobre el mismo dataset.

Estado: listo para producción el próximo mes.

Reemplazará la evaluación manual de ejecutivos de crédito.

No hubo auditoría de sesgo por segmento ni revisión legal/compliance.

Caso B: Manufactura — Mantenimiento Predictivo

Proyecto: Mantenimiento Predictivo de Línea de Producción

Institución: Manufacturera industrial, 3 plantas, ~1.200 máquinas en operación

Área responsable: Gerencia de Operaciones, con apoyo del equipo de Datos

Objetivo declarado: predecir qué máquinas fallarán en los próximos 30 días, para programar mantenimiento preventivo y evitar paradas no planificadas.

Datos utilizados:

- Fuente: sensores IoT (vibración, temperatura, presión) + historial de fallas (2020-2025)
- Solo se incluyeron máquinas con al menos 2 años de sensores instalados (las líneas nuevas y la planta más pequeña quedaron fuera)
- Variables: vibración promedio, temperatura máxima, horas de uso, antigüedad, ¿tuvo mantenimiento correctivo de emergencia en los últimos 7 días?
- Muestra de entrenamiento: 45.000 lecturas diarias

Modelo: Random Forest. Métrica en pruebas: 96% de precisión.

Validación: split 80/20 aleatorio sobre el mismo dataset.

Estado: listo para producción el próximo trimestre.

Reemplazará las rondas de inspección manual de los técnicos.

No hubo revisión de si el modelo funciona igual en máquinas nuevas o en la planta más pequeña.

Parte 1 — Evaluación propia (sin LLM)

Lee el caso elegido y anota tu diagnóstico usando los 4 Enemigos Silenciosos. Para cada uno indica si está bien controlado, ausente o es riesgoso.

Enemigo	¿Bien controlado?	Riesgo que identificas
Representación		
Histórico		
Leakage		
Calidad		

¿Aprobarías este proyecto para producción? Sí / No / Con condiciones

¿Por qué?

Parte 2 — Evaluación con skill (con LLM)

Abre vibe (CLI oficial de Mistral) o, si no lo tienes instalado, pega el prompt directamente en <https://chat.mistral.ai>. Reemplaza [escenario] con el texto del caso elegido.

Actúa como auditor de gobernanza de datos especializado en proyectos de IA.

Los 4 Enemigos Silenciosos son un framework para auditar datos antes de llevar un modelo a producción:

1. Representación - ¿el dataset representa a todos los grupos que el modelo afectará (género, edad, geografía, nivel socioeconómico)?
2. Histórico - ¿los datos reflejan decisiones humanas del pasado que podrían haber sido injustas o discriminatorias?
3. Leakage - ¿alguna variable usada en el entrenamiento solo existiría DESPUÉS del momento en que se necesita predecir?
4. Calidad - ¿los datos están completos, actualizados y son consistentes entre sí?

Para cada enemigo indica:

- (1) qué está bien controlado en el proyecto
- (2) qué está ausente, es ambiguo o es riesgoso

Presenta el análisis como tabla:

Enemigo	Bien controlado	Riesgo identificado	Estado (Verde / Amarillo / Rojo)
---------	-----------------	---------------------	----------------------------------

Cierra con los 3 mayores riesgos y clasifica cada uno como:

bloqueante (no lanzar) / moderado (lanzar con plan) / menor (monitorear)

No inventes información que no esté en el escenario. Responde en español.

El proyecto es: [escenario]

Mensaje de prueba (Caso A): *“Banco quiere otorgar créditos automáticos usando 10 años de historial de otorgamientos y morosidad”*

Debrief

1. ¿Qué riesgos identificó el LLM que tú no habías visto en la Parte 1?
2. ¿Qué viste tú que el LLM no vio, o vio mal?
3. ¿Cambiarías algo del prompt para obtener un mejor diagnóstico?