

Fundamentos de Datos para la IA

Clase 01 – Calidad, Gobernanza, Pipelines y MLOps

2026-07-06

Sobre el docente

Experiencia, educación, etc.

Enlaces

-  sebastian.egana@udd.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Estructura de la clase

Bloque	Contenido	Duración
1	Datos como insumo crítico de la IA	~55 min
2	Data Pipelines para IA	~70 min
<i>Break</i>	—	15 min
3	MLOps: pipelines en producción	~40 min

Parte 1: El valor estratégico de los datos

Contexto actual

- Se generan más de **328 millones de TB** de datos diariamente (Statista, 2023).
 - Solo ~30 % de las empresas se consideran realmente *data-driven* (McKinsey, 2023).
 - El cuello de botella no es la IA — es la **calidad y disponibilidad del dato**.
-

La pregunta clave

No es “¿tenemos datos?”

Es “¿tenemos los datos correctos, limpios y listos para alimentar nuestros modelos?”

Tipos de datos para IA

Tipo	Descripción	Ejemplos	Desafíos principales
Estructurado	Tablas con esquema fijo	Transacciones, CRM, ERP	Integración entre sistemas
Semi-estructurado	Formato flexible	JSON, logs, XML, emails	Parsing y normalización
No estructurado	Sin esquema fijo	Texto, imágenes, audio, video	Requiere modelos especializados

¿Por qué importa el tipo de dato?

- Cada tipo requiere un **pipeline distinto**
 - Imagen → *Computer Vision* → OCR → LLM → respuesta
 - La arquitectura del sistema de IA depende del dato de entrada
 - Mezclar tipos de datos es hoy la norma, no la excepción (multimodal AI)
-

“Garbage in, garbage out”

- Ningún algoritmo corrige datos defectuosos
 - Un modelo entrenado con datos sesgados o incompletos amplifica esos problemas a escala
 - **La calidad del dato no es un problema de IT — es una responsabilidad de negocio**
-

Dimensiones de la calidad de datos

Dimensión	Descripción	Ejemplo
Completitud	Ausencia de valores faltantes	% de clientes sin RUT o correo
Exactitud	Concordancia con la realidad	Dirección o edad correcta
Consistencia	Coherencia entre sistemas	Fecha nacimiento vs. fecha de afiliación
Actualidad	Vigencia de la información	Cliente activo con contacto obsoleto
Unicidad	Sin registros duplicados	Mismo cliente en dos sistemas distintos

Riesgos de decisiones con datos de mala calidad

- **Operativos:** reprocesos, errores en informes, baja productividad
- **Financieros:** decisiones de inversión o riesgo erradas
- **Reputacionales:** pérdida de confianza del cliente o del regulador
- **Analíticos:** modelos con sesgos o predicciones inconsistentes

Gobernanza de datos

Conjunto de políticas, roles y procesos que aseguran el uso responsable y confiable de los datos.

- **Roles claros:** propietario, custodio, analista, consumidor
- **Catálogo de datos:** inventario de qué dato existe, dónde y qué significa
- **Linaje de datos:** rastrear de dónde viene un dato y cómo fue transformado
- **Control de acceso:** quién puede leer, modificar o eliminar cada dato

Ética y compliance en el uso de datos

- **Responsabilidad:** los datos son un activo compartido con impacto real en personas
- **Privacidad:** cumplir normativas — Ley 19.628 (Chile), GDPR (Europa)
- **Transparencia:** explicar decisiones automatizadas
- **Equidad:** auditar y corregir sesgos en modelos de IA

Actividad 1 — Calidad de datos (10 min)

En grupos de 3–4 personas, respondan:

1. ¿Cuál es el mayor problema de calidad de datos que tiene hoy su organización?
2. ¿Quién es el dueño formal de ese dato?
3. Si tuvieran que alimentar un modelo de IA con ese dato, ¿qué pasaría?

Un representante por grupo comparte brevemente con el curso.

Parte 2: Data Pipelines para IA

¿Qué es un pipeline de datos?

Una **secuencia automatizada de pasos** que mueve, transforma y prepara datos para su uso.

Analogía: línea de producción industrial. Si falla un paso, el producto final es defectuoso — aunque el resto esté perfecto.

Arquitectura típica de un pipeline para IA

Ingesta: cómo entra el dato al pipeline

- **Batch:** procesamiento programado (diario, horario) — ideal para datos históricos
 - **Streaming:** procesamiento en tiempo real — ideal para eventos y alertas
 - Fuentes comunes: APIs REST, bases de datos, archivos CSV/Parquet, eventos (Kafka, Pub/Sub)
-

Transformación y validación

- **Limpieza:** eliminar duplicados, tratar nulos, corregir tipos de dato
- **Normalización:** escalado, encoding de categorías, manejo de outliers
- **Validación de esquema:** ¿el dato tiene la estructura esperada?
- **Validación de calidad:** ¿los rangos son razonables? ¿hay registros faltantes inusuales?

Herramientas: **dbt** (transformación en SQL), **Great Expectations** (validación automática)

ETL vs ELT

	ETL	ELT
Proceso	Transforma <i>antes</i> de cargar	Carga primero, transforma <i>después</i>
Cuándo usar	Datos sensibles, sistemas legacy	Cloud data warehouses modernos
Ejemplo	Pipeline hacia DW on-premise	BigQuery + dbt
Ventaja	Control fino sobre los datos	Escalabilidad y velocidad

En contextos de IA con cloud, **ELT** es hoy el enfoque dominante.

Feature Engineering y Feature Stores

- **Feature:** variable transformada y lista para alimentar un modelo (ej. “meses desde última compra”)
- **Problema:** el mismo feature se calcula múltiples veces en distintos equipos, de formas distintas
- **Feature Store:** repositorio centralizado de features reutilizables y versionadas

Garantiza **consistencia entre entrenamiento y producción** — uno de los errores más comunes en MLOps.

Ejemplos: **Vertex AI Feature Store**, **Feast** (open source)

Herramienta 1: Apache Airflow

- Open source, ampliamente adoptado en la industria
- Define flujos como **DAGs** (grafos acíclicos dirigidos) en Python
- Ideal para: pipelines batch, ETL complejos, procesos periódicos
- Versión managed: **Cloud Composer** (GCP), **MWAA** (AWS)

Herramienta 2: Vertex AI Pipelines

- Basado en **Kubeflow Pipelines**, managed completamente en GCP
- Cada componente del pipeline es un **contenedor reproducible**
- Integración nativa con BigQuery, Vertex AI Training y Model Registry
- Pensado específicamente para **ML workflows** de extremo a extremo

Herramienta 3: MLflow

Open source (mantenido por Databricks), multicloud, agnóstico al framework de ML.

Componente	Función
MLflow Tracking	Registra experimentos: parámetros, métricas, artefactos
MLflow Projects	Empaqueta el código para reproducibilidad
MLflow Models	Formato estándar de modelo (sklearn, PyTorch, etc.)
MLflow Registry	Control de versiones y estado del modelo (Staging / Production)

MLflow en la práctica

El registry permite hacer rollback si una nueva versión falla en producción.

Comparativa de herramientas

Herramienta	Foco principal	Mejor para	¿Excluyentes?
Apache Airflow	Orquestación de datos	ETL/ELT, workflows batch	No
Vertex AI Pipelines	ML workflows en GCP	Training y deployment en nube	No
MLflow	Tracking y model registry	Experimentación y governance	No

En equipos maduros se usan los tres juntos: Airflow mueve los datos, Vertex entrena el modelo, MLflow registra los experimentos.

Ejemplo conceptual: pipeline de predicción de churn

Paso	Acción	Herramienta
1. Ingesta	Extraer datos del CRM diariamente	Airflow + BigQuery
2. Transformación	Limpiar, normalizar, tratar nulos	dbt

Paso	Acción	Herramienta
3. Validación	Verificar rangos y completitud	Great Expectations
4. Features	Calcular recencia, frecuencia, saldo promedio	Vertex AI Feature Store
5. Entrenamiento	Entrenar modelo con los features	Vertex AI Pipelines
6. Tracking	Registrar métricas y artefactos	MLflow
7. Deployment	Publicar modelo en endpoint REST	Vertex AI Endpoints
8. Acción	Alertar a ejecutivo de cuenta	Aplicación de negocio

Break — 15 minutos

Parte 3: MLOps — Pipelines en producción

El problema del “modelo en producción”

- Un modelo que funciona en el notebook **no es un producto**
 - La brecha entre *data science* y *software engineering* es real y costosa
 - **MLOps:** prácticas para llevar ML a producción de forma confiable, repetible y auditable
 - Analogía: DevOps para el ciclo de vida del software, adaptado a modelos de ML
-

Ciclo de vida de un modelo ML

Concepto	Definición	Síntoma	Acción
----------	------------	---------	--------

Data Drift, Model Drift y Concept Drift

Concepto	Definición	Síntoma	Acción
Data Drift	Cambia la distribución de los datos de entrada	Las features tienen rangos distintos a los de entrenamiento	Reingesta y reentrenamiento
Model Drift	El modelo pierde precisión en producción	Las métricas bajan vs. el baseline	Reentrenamiento o reemplazo
Concept Drift	Cambia la relación entre features y target	El comportamiento del cliente cambió	Replantear el modelo

Ejemplo real: un modelo de riesgo crediticio entrenado antes de la pandemia sufrió concept drift masivo en 2020.

Monitoreo en producción: tres niveles

Nivel	Qué se monitorea	Ejemplo
Técnico	Latencia, errores, disponibilidad	Endpoint responde en <200ms
Modelo	Distribución de predicciones, drift, performance	AUC cae de 0.91 a 0.78
Negocio	Impacto real en el KPI objetivo	Tasa de churn efectiva no baja

Sin monitoreo de los tres niveles, el sistema puede “funcionar” técnicamente mientras falla silenciosamente en el negocio.

El pipeline completo: visión integrada

Actividad 2 — Diseña un pipeline (20 min)

En grupos de 3–4 personas, elijan un proceso de su industria que podría mejorarse con IA.

Diseñen el pipeline respondiendo:

1. **Ingesta:** ¿Qué datos necesitan y de dónde vienen? (sistemas, frecuencia, batch o streaming)
2. **Transformación:** ¿Qué limpieza o cálculos son necesarios?
3. **Validación:** ¿Cómo garantizarían la calidad antes de que el dato llegue al modelo?
4. **Monitoreo:** ¿Qué indicaría que el modelo está fallando en producción?

Preparen 3–4 minutos para presentar al curso.

Cierre

Checklist para líderes

-  ¿Tenemos definido quién es el **dueño de cada dato crítico** para IA?
 -  ¿Nuestros pipelines son **automatizados** o dependemos de procesos manuales?
 -  ¿Sabemos qué pasa cuando **los datos cambian** inesperadamente?
 -  ¿Tenemos **visibilidad del desempeño** de nuestros modelos en producción?
 -  ¿Existe un proceso claro para **reentrenar modelos** cuando sea necesario?
 -  ¿Auditamos periódicamente los modelos en búsqueda de **sesgos o drift**?
-

Idea central

La IA es tan buena como el pipeline que la alimenta.

Un modelo brillante sobre datos sucios es un modelo inútil.

Referencias

- Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., ... & Dennison, D. (2015). Hidden technical debt in machine learning systems. *Advances in neural information processing systems*, 28. https://proceedings.neurips.cc/paper_files/paper/2015/file/86df7dcfd896fcaf2674f757a2463eba-Paper.pdf
- Breck, E., Cai, S., Nielsen, E., Salib, M., & Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. *IEEE International Conference on Big Data*. <https://research.google/pubs/the-ml-test-score-a-rubric-for-ml-production-readiness-and-technical-debt-reduction/>
- Paleyes, A., Urma, R. G., & Lawrence, N. D. (2022). Challenges in deploying machine learning: a survey of case studies. *ACM computing surveys*, 55(6), 1–29. <https://arxiv.org/abs/2011.09926>
- Google Cloud. (2024). *Vertex AI Pipelines documentation*. <https://cloud.google.com/vertex-ai/docs/pipelines/introduction>
- MLflow. (2024). *MLflow documentation*. <https://mlflow.org/docs/latest/index.html>