

Fundamentos de Datos para la Toma de Decisiones Estratégicas con IA

Diplomado en IA para la Transformación Empresarial

2026-05-18

Sobre el docente

Enlaces

-  sebastian.egana@udd.cl
 -  <https://segana.netlify.app>
 -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
 -  <https://github.com/sebaegana>
-

Descripción General

Este módulo capacita para comprender el valor estratégico de los datos, identificar riesgos ocultos y tomar decisiones informadas sobre proyectos de IA.

Sin requerir programación, aprenderán a hacer **preguntas críticas** dentro de sus equipos y a gobernar responsablemente iniciativas de IA.

Objetivos de Aprendizaje

Al finalizar esta sesión podrán:

1. Entender por qué los datos son el **cimiento crítico** de la IA
 2. Identificar los **4 enemigos silenciosos** de los datos
 3. Reconocer **riesgos específicos** en sus industrias
 4. Formular las **5 preguntas clave** antes de implementar IA
 5. Diseñar un proceso básico de **auditoría de datos**
-

Estructura de la Sesión

Bloque	Duración	Contenido
1	50 + 10 min	El combustible de la IA: datos como diferenciador
2	50 + 10 min	Los enemigos silenciosos: sesgos, calidad, leakage
3	50 + 10 min	Gobernanza y toma de decisiones informadas

Bloque 1: El Combustible de la IA

Concepto Central: Datos Información


Lo que la mayoría piensa:

- IA es magia / inteligencia artificial
- Con suficientes datos, la IA funciona

La realidad:

- IA es **estadística + patrones en datos**
 - **Calidad de datos > cantidad de datos**
 - Los datos son el combustible; el modelo es el motor
-

El Triángulo de Oro de la IA



La Fórmula

Escenario	Resultado
Datos buenos + features relevantes + modelo simple	Éxito
Datos malos + features complicadas + modelo sofisticado	Fracaso

Puedes tener el algoritmo más avanzado del mundo. Si los datos son malos, el resultado será malo.

Caso: Netflix vs YouTube

Aspecto	Netflix	YouTube
Datos que tienen	Historial, ratings, tiempo visto, contexto (país, horario)	Billones de vistas, pero datos demográficos limitados
Calidad de datos	Etiquetado claro (5 estrellas, visto completamente)	Ruidoso (clickbait, clicks accidentales)

Aspecto	Netflix	YouTube
Resultado	Recomendaciones precisas	Recomendaciones genéricas

Lección: Netflix tiene *menos datos* pero mejor **calidad y relevancia**.

Caso: Spotify y los Datos Contextuales

Spotify ganó no por tener más datos, sino por capturar los datos **correctos**:

- Qué escuchas a las 6 AM vs las 10 PM
- Si repites una canción
- Si saltas después de 5 segundos
- Contexto: gym, trabajo, fiesta

Primer insight: *Éxito en IA = elegir los datos correctos, no acumular todos los datos.*

La Pregunta Clave para Líderes

“¿Qué datos tenemos nosotros que nuestros competidores **NO** tienen?”


Eso es tu ventaja competitiva en IA.

No es el algoritmo — todos usan los mismos. Es **qué datos únicos capturas de tu negocio**.

Actividad 1 — Diagnóstico de Datos (10 min)

Piensa en tu área/empresa y responde:

- 1. ¿Qué datos generamos hoy que nunca capturamos?** - Retail: captura punto de venta, pero NO el momento en que el cliente decide NO comprar - HR: captura performance review, pero NO conversaciones 1:1 informales
 - 2. ¿Qué datos tenemos que podrían revelar algo escondido?** - Bancos: historial de transacciones → ¿cuándo alguien está en riesgo financiero? - Logística: rutas → ¿cuándo el costo de entrega será más alto?
 - 3. ¿Quién en nuestra organización NO está representado en nuestros datos?** - ¿Solo clientes que compraron? ¿No los que visitaron y no compraron? - ¿Solo empleados en sede? ¿No remotos?
-
-



Bloque 2: Los Enemigos Silenciosos

Los 4 Enemigos

Enemigo	Causa	Red Flag
Representación	Falta un grupo demográfico	“Funciona bien para el cliente típico”
Histórico	Datos reflejan prejuicios del pasado	“Reflejaría cómo siempre lo hemos hecho”

Enemigo	Causa	Red Flag
Leakage	Información futura en datos de entrenamiento	“99 % de precisión” (sospechosamente alto)
Calidad	Datos incompletos, incorrectos o viejos	“Nuestros datos están desordenados”

Enemigo #1: Sesgo de Representación

Definición: Tu dataset **no representa** a toda la población que afectará la IA.

Caso Real: Reconocimiento Facial

Problema descubierto (2018):

- Google, Amazon, Microsoft: **tasa de error del 34 % en rostros de mujeres oscuras**
- Tasa de error del 0.7 % en rostros de hombres blancos

¿Por qué? Los modelos se entrenaron mayormente con datos de personas blancas.

Impacto:

- Policía usa algoritmo para identificar sospechosos → falla en comunidades afrodescendientes
 - Acceso a edificios por facial → gente con piel oscura queda afuera
-

Caso Real: Modelos de Crédito

Problema:

- Banco entrena algoritmo con datos históricos de clientes de clase media-alta
- Algoritmo rechaza más personas de clase baja, aunque sean buen riesgo crediticio

Razón: no hay suficientes datos de ese grupo en el histórico

Impacto:

- Discriminación indirecta pero efectiva
 - Mercado perdido (no alcanzas segmentos nuevos)
 - Regulatorio: Regulador podría penalizar (CMF)
-

Cómo Identificar el Sesgo de Representación

Red flags:

- “Nuestro modelo funciona bien para el cliente típico”
- “Estos grupos son muy pequeños en nuestros datos”
- “Hay outliers raros que el modelo rechaza”

Test simple:

1. Segmenta tu dataset por: género, edad, geografía, nivel socioeconómico
 2. ¿El modelo funciona **bien** en **todos** los segmentos?
 3. Si no → **hay sesgo de representación**
-

Enemigo #2: Sesgo Histórico

Definición: Entrenas un modelo con datos del pasado que reflejan injusticias del pasado. El modelo las **perpetúa**.

Caso Real: Amazon Hiring Algorithm (2014–2018)

¿Qué pasó?

- Amazon creó un algoritmo para filtrar CVs automáticamente
- Lo entrenó con 10 años de contrataciones históricas en tech
- **Problema:** históricamente contrataban más hombres en tech - **Resultado:** el algoritmo aprendió a rechazar mujeres

Detalles perturbadores:

- Rechazaba palabras como *“women’s chess club”*
- Rechazaba CVs de egresadas de colegios para mujeres

Amazon mató el proyecto en 2018. No por altruismo: costoso en reputación y legal.

Caso Real: Sistema de Justicia Criminal

¿Qué pasó?

- Policía usa el algoritmo COMPAS para predecir reincidencia
- Entrenado con datos históricos de quién fue detenido antes
- **Problema:** el sistema penal históricamente sobre-arresta a gente negra
- **Resultado:** el algoritmo predice más reincidencia en gente negra (lógica circular)

Preguntas sin respuesta:

- ¿Fue reincidencia... o simplemente los arrestaron otra vez?
 - ¿El algoritmo predice crimen o predice quién será arrestado?
-

Cómo Identificar el Sesgo Histórico

Red flags:

- “Nuestro modelo refleja lo que siempre hemos hecho”
- “Usamos datos históricos de evaluaciones / contrataciones / decisiones”
- “El modelo mantiene el status quo”

Test:

1. ¿Tus datos vienen de decisiones humanas del pasado?
 2. ¿Esas decisiones eran justas / objetivas?
 3. Si la respuesta no es un “sí” claro → **hay sesgo histórico**
-

Enemigo #3: Data Leakage

Definición: El modelo usa información que **no tendría disponible** en producción real. Parece perfecto en pruebas; falla en la realidad.

Caso Real: Predicción de Fraude

Caso Real: Predicción de Mortalidad Hospitalaria

Data Leakage: Predicción de Deserción Escolar

Lo que FUNCIONA:

- Datos de hace 2 meses: asistencia, notas, engagement
- Predecir: ¿desertor en próximos 3 meses?

Lo que NO funciona:

- Incluir: “¿Se retiró del colegio?” — ¡eso es exactamente lo que predices!
- Resultado: 100 % de precisión, modelo completamente inútil

Si el KPI es demasiado bueno (>95 %), busca leakage.

Cómo Detectar Data Leakage

Pregunta clave:

> “¿Toda la información del modelo estaría disponible en el momento exacto en que necesitamos predecir?”

Red flags:

- KPI de precisión > 99 % (sospechosamente perfecto)
 - El outcome (lo que predices) aparece como variable en el modelo
 - Datos que solo existen **después** del evento que predices
-

Enemigo #4: Calidad de Datos

Definición: Datos incompletos, incorrectos, contradictorios o desactualizados.

Problema	Ejemplo	Impacto
Incompletos	30 % de edad faltante en CRM	El modelo rechaza registros o asume mal
Incorrectos	Cliente registrado 2 veces con edades distintas	Inconsistencia en decisiones
Desactualizados	Dirección de cliente de 2015	Marketing envía a dirección incorrecta
Contradictorios	“Estado: activo” pero “fecha baja: 2020”	Confusión en la lógica de negocio
Sesgados en entrada	Solo se registran clientes que compraron	El modelo no ve quién NO compra

La Realidad Incómoda

El 80 % del tiempo en un proyecto de IA es limpieza de datos.

No es atractivo. No es “IA”. Pero es **crítico**.

Test simple de calidad:

1. Toma 100 registros aleatorios
2. Valídalos manualmente: ¿son correctos?
3. Si $< 95\%$ correcto → **hay problema de calidad**

Resumen: Los 4 Enemigos

Enemigo	Causa	Impacto	Red Flag
Representación	Falta un grupo demográfico	Modelo falla para ese grupo	“Funciona bien para el cliente típico”
Histórico	Datos reflejan prejuicios del pasado	Perpetúa injusticia a escala	“Refleja cómo siempre lo hicimos”
Leakage	Información futura en entrenamiento	KPI falso; falla en producción	“99 % de precisión”
Calidad	Datos incompletos, incorrectos o viejos	Decisiones inconsistentes	“Nuestros datos están desordenados”

Actividad 2 — Diagnóstico de Riesgos (10 min)

Escenario: tu empresa implementará IA en los próximos 6 meses.

Identifica 1–2 riesgos por categoría:

- **Sesgo de Representación:** ¿hay grupos sub-representados en tus datos?
 - Ej. Retail: ¿solo tiendas físicas, no web?
- **Sesgo Histórico:** ¿tus datos vienen de decisiones humanas del pasado? ¿eran justas?
 - Ej. Hiring: ¿datos de hace 10 años cuando contrataban diferente?
- **Data Leakage:** ¿hay información que “solo sabrías después”?
 - Ej. Churn: ¿incluyes si el cliente llamó a cancelar? (¡ya está cancelado!)
- **Calidad:** ¿qué tan limpia está tu data? ¿hay valores faltantes críticos?

Bloque 3: Gobernanza y Toma de Decisiones

Las 5 Preguntas que Todo Líder Debe Hacer

Antes de aprobar cualquier proyecto de IA, formula estas preguntas a tu equipo técnico:

1. ¿Quién está representado en estos datos?
 2. ¿Estos datos reflejan decisiones justas del pasado?
 3. ¿Hay información aquí que no tendríamos al momento de decidir?
 4. ¿Qué tan limpia y confiable es esta data?
 5. ¿Cómo sabemos si el modelo falla? ¿Quién lo vigila?
-

Pregunta 1: ¿Quién está representado?

Por qué: identificar sesgos de representación.

Cómo preguntar: - “¿Todos nuestros clientes / empleados están en estos datos?” - “¿Hay grupos que falten? ¿Qué pasará con ellos?”

Señales de respuesta: - ✓ “80 % de nuestros clientes activos, distribuidos así...” - ✗ “Suficientes datos” - ✗ “No es importante”

Acción si hay riesgo: - Recolectar datos del grupo faltante - Limitar el scope: “este modelo es solo para clientes premium” - Monitorear sesgo por segmento

Pregunta 2: ¿Los históricos fueron justos?

Por qué: identificar sesgo histórico que perpetúa injusticia.

Cómo preguntar: - “¿De dónde vienen estos datos históricos?” - “¿Las decisiones del pasado fueron justas? ¿O reflejan cómo discriminábamos?”

Señales de respuesta: - ✓ “Datos de decisiones que auditamos y validamos” - ✗ “Datos de cómo siempre lo hemos hecho” - ✗ “Asumimos que el histórico es objetivo”

Acción si hay riesgo: - Auditar las decisiones históricas - Limpiar datos discriminatorios - Limitar el impacto: recomendación (no decisión automática)

Pregunta 3: ¿Hay data leakage?

Por qué: detectar información futura infiltrada en el entrenamiento.

Cómo preguntar: - “¿Cuándo predecimos esto exactamente?” - “¿Toda esta información estaría disponible EN ESE MOMENTO?”

Ejemplo de conversación:

Tú: “¿Incluyen la variable ‘fue reportado como fraude’ en entrenamiento?”

Técnico: “Sí.”

Tú: “¿En producción, cuando necesitamos predecir, ya sabremos eso?”

Técnico: “Ah... no. Eso se sabe después.”

Tú: “Saca esa variable. El modelo está truqueado.”

Pregunta 4: ¿Qué tan limpia es la data?

Por qué: calidad de datos = confiabilidad de las decisiones.

Cómo preguntar: - “¿Cuánto tiempo se invirtió en limpieza?” - “¿Qué porcentaje está incompleto? ¿Qué tan actualizado está?”

Señales de respuesta: - ✓ “80 % del tiempo fue limpieza. Datos 95 %+ correctos. Revisión mensual.” - ✗ “Usamos datos como están. Probablemente esté bien.”

Benchmark:

Proyecto	% tiempo en limpieza
Pequeño	~50 %
Grande	~80 %
Sospechoso	<30 %

Pregunta 5: ¿Quién vigila el modelo?

Por qué: datos y modelos cambian; el sesgo puede aparecer con el tiempo.

Cómo preguntar: - “¿Cómo monitorean el desempeño en el mundo real?” - “¿Quién es responsable si falla?” - “¿Qué pasaría si el modelo empieza a favorecer a un grupo?”

Señales de respuesta: - ✓ “Dashboard mensual. Métricas por segmento demográfico. Alertas automáticas.” - ✗ “Asumimos que funciona igual que en el test.” - ✗ “No lo hemos pensado.”

Acción si hay riesgo: - Establecer SLAs y alertas - Plan de rollback (cómo parar rápido si falla) - Auditoría trimestral

Cuadro de Decisión: ¿Apruebo Este Proyecto?

Pregunta	Sí	No	Con riesgo
¿Todos los grupos están representados?	✓ Adelante	✗ No aprobar	⚠ Limitar scope
¿Datos históricos fueron justos?	✓ Adelante	✗ No aprobar	⚠ Auditar y limpiar
¿Sin data leakage?	✓ Adelante	✗ No aprobar	⚠ Remover variables
¿Datos >95 % limpios?	✓ Adelante	✗ No aprobar	⚠ Invertir en limpieza
¿Hay monitoreo?	✓ Adelante	✗ No aprobar	⚠ Implementar primero

Criterio de aprobación: al menos 4/5 deben ser “Sí” (o “Con riesgo” + plan concreto).

El Rol del Líder en Gobernanza de Datos

No tienes que ser técnico. Pero tienes que:

1. **Hacer preguntas incómodas** — sin miedo a parecer ignorante
2. **Entender los riesgos** — sesgos, leakage, calidad
3. **Establecer estándares** — auditoría, monitoreo, responsabilidad
4. **Actuar si hay problemas** — parar, revisar, remediar

Si un modelo falla y afecta a clientes o empleados, tú eres responsable.

Actividad 3 — Simulación: “Aprobación de Proyecto” (10 min)

Elige uno de estos proyectos y formula las 5 preguntas. Luego decide: ¿Aprobado? ¿Con riesgos? ¿Rechazado?

Opción	Propuesta	Datos	Beneficio esperado
A: Fintech	Créditos automáticos	10 años de otorgamientos + morosidad	Ahorrar 2 horas por solicitud
B: Retail	Recomendador personalizado	Historial de compras online	+15 % en ticket promedio
C: HR	Identificar candidatos de alto potencial	CVs, desempeño, evaluaciones históricas	Reducir turnover
D: Manufactura	Mantenimiento predictivo	Sensores + histórico de fallas	Reducir downtime 40 %

Ejemplo: “¿Los datos incluyen todos los estratos socioeconómicos? → No solo clase media-alta → Sesgo de representación → Aprobado CON riesgo: necesitamos datos más amplios + monitoreo por estrato.”

Los 3 Pilares de una Gobernanza Responsable

Pilar 1 — Transparencia - ¿De dónde vienen los datos? - ¿Quién está representado? - ¿Qué decisiones se tomaron históricamente?

Pilar 2 — Validación - ¿Datos están limpios? - ¿Hay sesgos detectables? - ¿El modelo funciona igual para todos los grupos?

Pilar 3 — Monitoreo - ¿Vigilamos el modelo en producción? - ¿Detectamos cambios o degradación? - ¿Tenemos plan de rollback?

Red Flags: Cuándo Desconfiar

Frase	Red Flag	Acción
“Los datos están limpios” (sin explicar cómo)	Falta transparencia	Pide detalles del proceso
“El modelo funciona con 99 % de precisión”	Data leakage posible	Valida las variables
“Estos grupos son muy pequeños, no importa”	Sesgo aceptado	Cuestiona y exige representación
“Nuestro histórico es objetivo” (sin auditarlo)	Sesgo histórico oculto	Pide auditoría de decisiones
“No sabemos qué vigilar en producción”	Falta de gobernanza	Exige plan antes de aprobar
“Solo el equipo técnico entiende esto”	Opacidad deliberada	Demanda explicaciones claras

Red Flags: Cuándo Desconfiar

Frase	Red Flag	Acción
“Nuestro histórico es objetivo” (sin auditarlo)	Sesgo histórico oculto	Pide auditoría de decisiones
“No sabemos qué vigilar en producción”	Falta de gobernanza	Exige plan antes de aprobar
“Solo el equipo técnico entiende esto”	Opacidad deliberada	Demanda explicaciones claras

Checklist para Líderes: Antes de Aprobar

¿Representación de datos? ¿Hay grupos sub-representados?
¿Datos históricos validados como justos / objetivos?
¿Variables sin data leakage?
¿Datos >95% limpios? ¿Quién verifica?
¿Plan de monitoreo y alertas?
¿Responsabilidades claras (quién es accountable si falla)?
¿Proceso de rollback si falla?
¿Testeado con grupos minoritarios?
¿Documentación clara del dataset?
¿Auditoría independiente (si el impacto es alto)?

Checklist de Monitoreo Mensual

¿El modelo sigue funcionando igual que hace 30 días?
¿Hay cambios en el desempeño por segmento?
¿Hay alertas de anomalías activas?
¿Se actualizó la data? ¿Cómo impactó?
¿Hay feedback de usuarios sobre errores o sesgos?
¿Necesitamos reentrenar?

Cierre: La Responsabilidad del Líder

“Datos es poder. El poder requiere responsabilidad.”

No necesitas ser Data Scientist para liderar con integridad. Necesitas:

- **Curiosidad** — hacer preguntas
- **Escepticismo sano** — dudar de resultados perfectos
- **Empatía** — pensar en quién se ve afectado
- **Coraje** — parar un proyecto si tiene riesgo

El 80 % de los fracasos en IA no son por tecnología. Son por datos malos, sesgos ocultos y líderes que no hicieron preguntas.

Anexo

Glosario para Líderes

Término	Definición simple
Dataset	Tabla con filas (ejemplos) y columnas (datos)
Sesgo	El modelo favorece o rechaza a un grupo sin razón válida
Data Leakage	Información futura “filtrada” en datos de entrenamiento
Overfitting	Modelo que memoriza en lugar de aprender patrones generalizables
Feature	Una columna de datos: edad, ubicación, historial de compras
Entrenamiento	Proceso donde el modelo aprende patrones desde los datos

Glosario para Líderes

Término	Definición simple
Validación	Testear el modelo en datos nuevos (no usados en entrenamiento)
Producción	El modelo en uso real, haciendo predicciones
KPI	Métrica de desempeño (ej. “precisión 95 %”)
Monitoreo	Vigilar que el modelo siga funcionando correctamente

Lecturas Recomendadas

- **Weapons of Math Destruction** — Cathy O’Neil (*accesible, crítico*)
- **Fairness and Machine Learning** — Barocas, Hardt & Narayanan (*más técnico pero abordable*)

Casos de estudio:

- Amazon Hiring Algorithm (2018) — sesgo histórico en contratación
- COMPAS (justicia criminal) — sesgo histórico en sistema penal
- Gender Shades — Buolamwini & Gebru (MIT, 2018) — sesgo de representación en reconocimiento facial

Referencias

- Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 77–91. <http://proceedings.mlr.press/v81/buolamwini18a.html>
- Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and Machine Learning: Limitations and Opportunities*. MIT Press. <https://fairmlbook.org>
- O’Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown Publishers.
- Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016). Machine bias. *ProPublica*. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
- Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*. <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>