

# Fundamentos de Datos para la Toma de Decisiones Estratégicas con IA

Diplomado en IA para la Transformación Empresarial

2026-07-06

## Sobre el docente

## Enlaces

-  sebastian.egana@udd.cl
  -  <https://segana.netlify.app>
  -  <https://www.linkedin.com/in/sebastian-egana-santibanez/>
  -  <https://github.com/sebaegana>
- 

## Descripción General

Este módulo capacita para comprender el valor estratégico de los datos, identificar riesgos ocultos y tomar decisiones informadas sobre proyectos de IA.

Sin requerir programación, aprenderán a hacer **preguntas críticas** dentro de sus equipos y a gobernar responsablemente iniciativas de IA.

---

## Objetivos de Aprendizaje

Al finalizar esta sesión podrán:

1. Entender por qué los datos son el **cimiento crítico** de la IA
  2. Identificar los **4 enemigos silenciosos** de los datos
  3. Reconocer **riesgos específicos** en sus industrias
  4. Formular las **5 preguntas clave** antes de implementar IA
  5. Diseñar un proceso básico de **auditoría de datos**
-

## Estructura de la Sesión

| Bloque   | Duración    | Contenido                                          |
|----------|-------------|----------------------------------------------------|
| <b>1</b> | 50 + 10 min | El combustible de la IA: datos como diferenciador  |
| <b>2</b> | 50 + 10 min | Los enemigos silenciosos: sesgos, calidad, leakage |
| <b>3</b> | 50 + 15 min | Gobernanza y toma de decisiones informadas         |

---

## Bloque 1: El Combustible de la IA

---

### Concepto Central: Datos   Información


#### Lo que la mayoría piensa:

- IA es magia / inteligencia artificial
- Con suficientes datos, la IA funciona

#### La realidad:

- IA es **estadística + patrones en datos**
  - **Calidad de datos > cantidad de datos**
  - Los datos son el combustible; el modelo es el motor
-

## El Triángulo de Oro de la IA



## La Fórmula

| Escenario                                                      | Resultado      |
|----------------------------------------------------------------|----------------|
| <b>Datos buenos</b> + features relevantes + modelo simple      | <b>Éxito</b>   |
| <b>Datos malos</b> + features complicadas + modelo sofisticado | <b>Fracaso</b> |

*Puedes tener el algoritmo más avanzado del mundo. Si los datos son malos, el resultado será malo.*

## Caso: Netflix vs YouTube

| Aspecto                 | Netflix                                                    | YouTube                                               |
|-------------------------|------------------------------------------------------------|-------------------------------------------------------|
| <b>Datos que tienen</b> | Historial, ratings, tiempo visto, contexto (país, horario) | Billones de vistas, pero datos demográficos limitados |
| <b>Calidad de datos</b> | Etiquetado claro (5 estrellas, visto completamente)        | Ruidoso (clickbait, clicks accidentales)              |

| Aspecto          | Netflix                  | YouTube                   |
|------------------|--------------------------|---------------------------|
| <b>Resultado</b> | Recomendaciones precisas | Recomendaciones genéricas |

**Lección:** Netflix tiene *menos datos* pero mejor **calidad y relevancia**.

---

## Caso: Spotify y los Datos Contextuales

Spotify ganó no por tener más datos, sino por capturar los datos **correctos**:

- Qué escuchas a las 6 AM vs las 10 PM
- Si repites una canción
- Si saltas después de 5 segundos
- Contexto: gym, trabajo, fiesta

**Primer insight:** *Éxito en IA = elegir los datos correctos, no acumular todos los datos.*

---

## La Pregunta Clave para Líderes

“¿Qué datos tenemos nosotros que nuestros competidores NO tienen?”

Eso es tu ventaja competitiva en IA.


No es el algoritmo — todos usan los mismos. Es **qué datos únicos capturas de tu negocio**.

---

## Actividad 1 — Diagnóstico de Datos (10 min)

Piensa en tu área/empresa y responde:

- 1. ¿Qué datos generamos hoy que nunca capturamos?** - Retail: captura punto de venta, pero NO el momento en que el cliente decide NO comprar - HR: captura performance review, pero NO conversaciones 1:1 informales
  - 2. ¿Qué datos tenemos que podrían revelar algo escondido?** - Bancos: historial de transacciones → ¿cuándo alguien está en riesgo financiero? - Logística: rutas → ¿cuándo el costo de entrega será más alto?
  - 3. ¿Quién en nuestra organización NO está representado en nuestros datos?** - ¿Solo clientes que compraron? ¿No los que visitaron y no compraron? - ¿Solo empleados en sede? ¿No remotos?
- 
-



---

## Bloque 2: Los Enemigos Silenciosos

---

### Los 4 Enemigos

| Enemigo        | Causa                                | Red Flag                                 |
|----------------|--------------------------------------|------------------------------------------|
| Representación | Falta un grupo demográfico           | “Funciona bien para el cliente típico”   |
| Histórico      | Datos reflejan prejuicios del pasado | “Reflejaría cómo siempre lo hemos hecho” |

| Enemigo        | Causa                                        | Red Flag                                   |
|----------------|----------------------------------------------|--------------------------------------------|
| <b>Leakage</b> | Información futura en datos de entrenamiento | “99 % de precisión” (sospechosamente alto) |
| <b>Calidad</b> | Datos incompletos, incorrectos o viejos      | “Nuestros datos están desordenados”        |

---

## Enemigo #1: Sesgo de Representación

**Definición:** Tu dataset **no representa** a toda la población que afectará la IA.

---

### Caso Real: Reconocimiento Facial

**Problema descubierto (2018):**

- Google, Amazon, Microsoft: **tasa de error del 34 % en rostros de mujeres oscuras**
- Tasa de error del 0.7 % en rostros de hombres blancos

**¿Por qué?** Los modelos se entrenaron mayormente con datos de personas blancas.

---

### Caso Real: Reconocimiento Facial (Impacto)

**Impacto:**

- Policía usa algoritmo para identificar sospechosos → falla en comunidades afrodescendientes
- Acceso a edificios por facial → gente con piel oscura queda afuera

---

### Caso Real: Modelos de Crédito

**Problema:**

- Banco entrena algoritmo con datos históricos de clientes de clase media-alta
- Algoritmo rechaza más personas de clase baja, aunque sean buen riesgo crediticio

**Razón:** no hay suficientes datos de ese grupo en el histórico

## Caso Real: Modelos de Crédito (Impacto)

### Impacto:

- Discriminación indirecta pero efectiva
  - Mercado perdido (no alcanzas segmentos nuevos)
  - Regulatorio: Regulador podría penalizar (CMF)
- 

## Cómo Identificar el Sesgo de Representación

### Red flags:

- “Nuestro modelo funciona bien para el cliente típico”
- “Estos grupos son muy pequeños en nuestros datos”
- “Hay outliers raros que el modelo rechaza”

### Test simple:

1. Segmenta tu dataset por: género, edad, geografía, nivel socioeconómico
  2. ¿El modelo funciona **bien** en **todos** los segmentos?
  3. Si no → **hay sesgo de representación**
- 

## Enemigo #2: Sesgo Histórico

**Definición:** Entrenas un modelo con datos del pasado que reflejan injusticias del pasado. El modelo las **perpetúa**.

---

## Caso Real: Amazon Hiring Algorithm (2014–2018)

### ¿Qué pasó?

- Amazon creó un algoritmo para filtrar CVs automáticamente
  - Lo entrenó con 10 años de contrataciones históricas en tech
  - **Problema:** históricamente contrataban más hombres en tech - **Resultado:** el algoritmo aprendió a rechazar mujeres
-

## Caso Real: Amazon Hiring Algorithm (Detalles)

### Detalles perturbadores:

- Rechazaba palabras como “*women’s chess club*”
- Rechazaba CVs de egresadas de colegios para mujeres

Amazon mató el proyecto en 2018. No por altruismo: costoso en reputación y legal.

---

## Caso Real: Sistema de Justicia Criminal

### ¿Qué pasó?

- Policía usa el algoritmo COMPAS para predecir reincidencia
  - Entrenado con datos históricos de quién fue detenido antes
  - **Problema:** el sistema penal históricamente sobre-arresta a gente negra
  - **Resultado:** el algoritmo predice más reincidencia en gente negra (lógica circular)
- 

## Caso Real: Sistema de Justicia Criminal (Preguntas)

### Preguntas sin respuesta:

- ¿Fue reincidencia... o simplemente los arrestaron otra vez?
  - ¿El algoritmo predice crimen o predice quién será arrestado?
- 

## Cómo Identificar el Sesgo Histórico

### Red flags:

- “Nuestro modelo refleja lo que siempre hemos hecho”
- “Usamos datos históricos de evaluaciones / contrataciones / decisiones”
- “El modelo mantiene el status quo”

### Test:

1. ¿Tus datos vienen de decisiones humanas del pasado?
  2. ¿Esas decisiones eran justas / objetivas?
  3. Si la respuesta no es un “sí” claro → **hay sesgo histórico**
-



## Enemigo #3: Data Leakage

**Definición:** El modelo usa información que **no tendría disponible** en producción real. Parece perfecto en pruebas; falla en la realidad.

---

### Caso Real: Predicción de Fraude

---

### Caso Real: Predicción de Mortalidad Hospitalaria

---

## Data Leakage: Predicción de Deserción Escolar

### Lo que FUNCIONA:

- Datos de hace 2 meses: asistencia, notas, engagement
- Predecir: ¿desertor en próximos 3 meses?

### Lo que NO funciona:

- Incluir: “¿Se retiró del colegio?” — ¡eso es exactamente lo que predices!
- Resultado: 100 % de precisión, modelo completamente inútil

**Si el KPI es demasiado bueno (>95 %), busca leakage.**

---

## Cómo Detectar Data Leakage

### Pregunta clave:

> “¿Toda la información del modelo estaría disponible en el momento exacto en que necesitamos predecir?”

### Red flags:

- KPI de precisión > 99 % (sospechosamente perfecto)
  - El outcome (lo que predices) aparece como variable en el modelo
  - Datos que solo existen **después** del evento que predices
-

## Enemigo #4: Calidad de Datos

**Definición:** Datos incompletos, incorrectos, contradictorios o desactualizados.

| Problema               | Ejemplo                                         | Impacto                                 |
|------------------------|-------------------------------------------------|-----------------------------------------|
| <b>Incompletos</b>     | 30 % de edad faltante en CRM                    | El modelo rechaza registros o asume mal |
| <b>Incorrectos</b>     | Cliente registrado 2 veces con edades distintas | Inconsistencia en decisiones            |
| <b>Desactualizados</b> | Dirección de cliente de 2015                    | Marketing envía a dirección incorrecta  |

## Enemigo #4: Calidad de Datos (cont.)

| Problema                   | Ejemplo                                  | Impacto                           |
|----------------------------|------------------------------------------|-----------------------------------|
| <b>Contradictorios</b>     | “Estado: activo” pero “fecha baja: 2020” | Confusión en la lógica de negocio |
| <b>Sesgados en entrada</b> | Solo se registran clientes que compraron | El modelo no ve quién NO compra   |

## La Realidad Incómoda

**El 80 % del tiempo en un proyecto de IA es limpieza de datos.**

No es atractivo. No es “IA”. Pero es **crítico**.

**Test simple de calidad:**

1. Toma 100 registros aleatorios
2. Valídalos manualmente: ¿son correctos?
3. Si  $< 95\%$  correcto → **hay problema de calidad**

| Enemigo | Causa | Impacto | Red Flag |
|---------|-------|---------|----------|
|---------|-------|---------|----------|

## Resumen: Los 4 Enemigos

| Enemigo               | Causa                                   | Impacto                        | Red Flag                               |
|-----------------------|-----------------------------------------|--------------------------------|----------------------------------------|
| <b>Representación</b> | Falta un grupo demográfico              | Modelo falla para ese grupo    | “Funciona bien para el cliente típico” |
| <b>Histórico</b>      | Datos reflejan prejuicios del pasado    | Perpetúa injusticia a escala   | “Refleja cómo siempre lo hicimos”      |
| <b>Leakage</b>        | Información futura en entrenamiento     | KPI falso; falla en producción | “99 % de precisión”                    |
| <b>Calidad</b>        | Datos incompletos, incorrectos o viejos | Decisiones inconsistentes      | “Nuestros datos están desordenados”    |

## Bloque 3: Gobernanza y Toma de Decisiones

### Las 5 Preguntas que Todo Líder Debe Hacer

Antes de aprobar cualquier proyecto de IA, formula estas preguntas a tu equipo técnico:

1. ¿Quién está representado en estos datos?
2. ¿Estos datos reflejan decisiones justas del pasado?
3. ¿Hay información aquí que no tendríamos al momento de decidir?
4. ¿Qué tan limpia y confiable es esta data?
5. ¿Cómo sabemos si el modelo falla? ¿Quién lo vigila?

### Pregunta 1: ¿Quién está representado?

**Por qué:** identificar sesgos de representación.

**Cómo preguntar:** - “¿Todos nuestros clientes / empleados están en estos datos?” - “¿Hay grupos que falten? ¿Qué pasará con ellos?”

**Señales de respuesta:** -  “80 % de nuestros clientes activos, distribuidos así...” -  “Suficientes datos” -  “No es importante”

**Acción si hay riesgo:** - Recolectar datos del grupo faltante - Limitar el scope: “este modelo es solo para clientes premium” - Monitorear sesgo por segmento

## Pregunta 2: ¿Los históricos fueron justos?

**Por qué:** identificar sesgo histórico que perpetúa injusticia.

**Cómo preguntar:** - “¿De dónde vienen estos datos históricos?” - “¿Las decisiones del pasado fueron justas? ¿O reflejan cómo discriminábamos?”

**Señales de respuesta:** - ✓ “Datos de decisiones que auditamos y validamos” - ✗ “Datos de cómo siempre lo hemos hecho” - ✗ “Asumimos que el histórico es objetivo”

**Acción si hay riesgo:** - Auditar las decisiones históricas - Limpiar datos discriminatorios - Limitar el impacto: recomendación (no decisión automática)

---

## Pregunta 3: ¿Hay data leakage?

**Por qué:** detectar información futura infiltrada en el entrenamiento.

**Cómo preguntar:** - “¿Cuándo predecimos esto exactamente?” - “¿Toda esta información estaría disponible EN ESE MOMENTO?”

**Ejemplo de conversación:**

Tú: “¿Incluyen la variable ‘fue reportado como fraude’ en entrenamiento?”

Técnico: “Sí.”

Tú: “¿En producción, cuando necesitamos predecir, ya sabremos eso?”

Técnico: “Ah... no. Eso se sabe después.”

Tú: “**Saca esa variable. El modelo está truqueado.**”

---

## Pregunta 4: ¿Qué tan limpia es la data?

**Por qué:** calidad de datos = confiabilidad de las decisiones.

**Cómo preguntar:** - “¿Cuánto tiempo se invirtió en limpieza?” - “¿Qué porcentaje está incompleto? ¿Qué tan actualizado está?”

**Señales de respuesta:** - ✓ “80 % del tiempo fue limpieza. Datos 95 %+ correctos. Revisión mensual.” - ✗ “Usamos datos como están. Probablemente esté bien.”

**Benchmark:**

---

| Proyecto   | % tiempo en limpieza |
|------------|----------------------|
| Pequeño    | ~50 %                |
| Grande     | ~80 %                |
| Sospechoso | <30 %                |

---

## Pregunta 5: ¿Quién vigila el modelo?

**Por qué:** datos y modelos cambian; el sesgo puede aparecer con el tiempo.

**Cómo preguntar:** - “¿Cómo monitorean el desempeño en el mundo real?” - “¿Quién es responsable si falla?” - “¿Qué pasaría si el modelo empieza a favorecer a un grupo?”

**Señales de respuesta:** - ✓ “Dashboard mensual. Métricas por segmento demográfico. Alertas automáticas.” - ✗ “Asumimos que funciona igual que en el test.” - ✗ “No lo hemos pensado.”

**Acción si hay riesgo:** - Establecer SLAs y alertas - Plan de rollback (cómo parar rápido si falla) - Auditoría trimestral

---

## Cuadro de Decisión: ¿Apruebo Este Proyecto?

| Pregunta                               | Sí         | No           | Con riesgo          |
|----------------------------------------|------------|--------------|---------------------|
| ¿Todos los grupos están representados? | ✓ Adelante | ✗ No aprobar | ⚠ Limitar scope     |
| ¿Datos históricos fueron justos?       | ✓ Adelante | ✗ No aprobar | ⚠ Auditar y limpiar |
| ¿Sin data leakage?                     | ✓ Adelante | ✗ No aprobar | ⚠ Remover variables |

---

## Cuadro de Decisión: ¿Apruebo Este Proyecto? (cont.)

| Pregunta              | Sí         | No           | Con riesgo             |
|-----------------------|------------|--------------|------------------------|
| ¿Datos >95 % limpios? | ✓ Adelante | ✗ No aprobar | ⚠ Invertir en limpieza |
| ¿Hay monitoreo?       | ✓ Adelante | ✗ No aprobar | ⚠ Implementar primero  |

**Criterio de aprobación:** al menos 4/5 deben ser “Sí” (o “Con riesgo” + plan concreto).

## El Rol del Líder en Gobernanza de Datos

No tienes que ser técnico. Pero tienes que:

1. **Hacer preguntas incómodas** — sin miedo a parecer ignorante
2. **Entender los riesgos** — sesgos, leakage, calidad
3. **Establecer estándares** — auditoría, monitoreo, responsabilidad
4. **Actuar si hay problemas** — parar, revisar, remediar

Si un modelo falla y afecta a clientes o empleados, tú eres responsable.

---

### ➤ Actividad 2 — Auditoría con IA (15 min)

- Trabajen en grupo con uno de los 2 casos del handout: Fintech (créditos automáticos) o Manufactura (mantenimiento predictivo)
- Parte 1: evalúen el proyecto ustedes mismos con los 4 Enemigos Silenciosos, **sin IA**
- Parte 2: auditen el mismo escenario con un LLM (**vibe**, el CLI oficial de Mistral, o <https://chat.mistral.ai>), usando el prompt-framework del handout
- Comparen: ¿la IA detectó lo mismo que ustedes? ¿qué se le pasó?

**Handout completo (escenario, tablas, prompt y debrief):** 202607\_actividad02\_skill-auditoria-datos.pdf

Preparación previa (no mostrar en pantalla): instalar y probar **vibe** con el prompt del handout antes de la clase. Backup si **vibe** falla en vivo: usar `auditar_mistral.ps1` (`.\clases\scripts\auditar_mistral.ps1` y `auditar "..."`) o directamente `chat.mistral.ai`. Repartir el handout `202607_actividad02_skill-auditoria-datos.pdf` antes de comenzar la actividad.

---

### Red Flags: Cuándo Desconfiar

| Frase                                            | Red Flag             | Acción                           |
|--------------------------------------------------|----------------------|----------------------------------|
| “Los datos están limpios”<br>(sin explicar cómo) | Falta transparencia  | Pide detalles del proceso        |
| “El modelo funciona con 99 % de precisión”       | Data leakage posible | Valida las variables             |
| “Estos grupos son muy pequeños, no importa”      | Sesgo aceptado       | Cuestiona y exige representación |

---

### Red Flags: Cuándo Desconfiar (cont.)

| Frase                                           | Red Flag               | Acción                       |
|-------------------------------------------------|------------------------|------------------------------|
| “Nuestro histórico es objetivo” (sin auditarlo) | Sesgo histórico oculto | Pide auditoría de decisiones |
| “No sabemos qué vigilar en producción”          | Falta de gobernanza    | Exige plan antes de aprobar  |
| “Solo el equipo técnico entiende esto”          | Opacidad deliberada    | Demanda explicaciones claras |

---

## Checklist para Líderes: Antes de Aprobar

¿Representación de datos? ¿Hay grupos sub-representados?  
 ¿Datos históricos validados como justos / objetivos?  
 ¿Variables sin data leakage?  
 ¿Datos >95% limpios? ¿Quién verifica?  
 ¿Plan de monitoreo y alertas?  
 ¿Responsabilidades claras (quién es accountable si falla)?  
 ¿Proceso de rollback si falla?  
 ¿Testeado con grupos minoritarios?  
 ¿Documentación clara del dataset?  
 ¿Auditoría independiente (si el impacto es alto)?

---

## Checklist de Monitoreo Mensual

¿El modelo sigue funcionando igual que hace 30 días?  
 ¿Hay cambios en el desempeño por segmento?  
 ¿Hay alertas de anomalías activas?  
 ¿Se actualizó la data? ¿Cómo impactó?  
 ¿Hay feedback de usuarios sobre errores o sesgos?  
 ¿Necesitamos reentrenar?

---

## Cierre: La Responsabilidad del Líder

**“Datos es poder. El poder requiere responsabilidad.”**

No necesitas ser Data Scientist para liderar con integridad. Necesitas:

- **Curiosidad** — hacer preguntas
- **Escepticismo sano** — dudar de resultados perfectos
- **Empatía** — pensar en quién se ve afectado
- **Coraje** — parar un proyecto si tiene riesgo

El 80 % de los fracasos en IA no son por tecnología. Son por datos malos, sesgos ocultos y líderes que no hicieron preguntas.

## Anexo

### Glosario para Líderes

| Término             | Definición simple                                        |
|---------------------|----------------------------------------------------------|
| <b>Dataset</b>      | Tabla con filas (ejemplos) y columnas (datos)            |
| <b>Sesgo</b>        | El modelo favorece o rechaza a un grupo sin razón válida |
| <b>Data Leakage</b> | Información futura “filtrada” en datos de entrenamiento  |

### Glosario para Líderes (cont.)

| Término              | Definición simple                                                |
|----------------------|------------------------------------------------------------------|
| <b>Overfitting</b>   | Modelo que memoriza en lugar de aprender patrones generalizables |
| <b>Feature</b>       | Una columna de datos: edad, ubicación, historial de compras      |
| <b>Entrenamiento</b> | Proceso donde el modelo aprende patrones desde los datos         |

### Glosario para Líderes

| Término           | Definición simple                                              |
|-------------------|----------------------------------------------------------------|
| <b>Validación</b> | Testear el modelo en datos nuevos (no usados en entrenamiento) |
| <b>Producción</b> | El modelo en uso real, haciendo predicciones                   |
| <b>KPI</b>        | Métrica de desempeño (ej. “precisión 95 %”)                    |
| <b>Monitoreo</b>  | Vigilar que el modelo siga funcionando correctamente           |



## Lecturas Recomendadas

- **Weapons of Math Destruction** — Cathy O’Neil (*accesible, crítico*)
- **Fairness and Machine Learning** — Barocas, Hardt & Narayanan (*más técnico pero abordable*)

### Casos de estudio:

- Amazon Hiring Algorithm (2018) — sesgo histórico en contratación
- COMPAS (justicia criminal) — sesgo histórico en sistema penal
- Gender Shades — Buolamwini & Gebru (MIT, 2018) — sesgo de representación en reconocimiento facial

---

## Referencias

Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 77–91. <http://proceedings.mlr.press/v81/buolamwini18a.html>

Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and Machine Learning: Limitations and Opportunities*. MIT Press. <https://fairmlbook.org>

O’Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown Publishers.

Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016). Machine bias. *ProPublica*. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>

Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*. <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>